

# Instituto Politécnico Nacional Escuela Superior de Cómputo



Práctica 3: Codificación de Huffman



### Integrantes:

Martinez Partida Jair Fabian

Martinez Rodriguez Alejandro

Monteros Cervantes Miguel Angel

Ramirez Cotonieto Luis Fernando

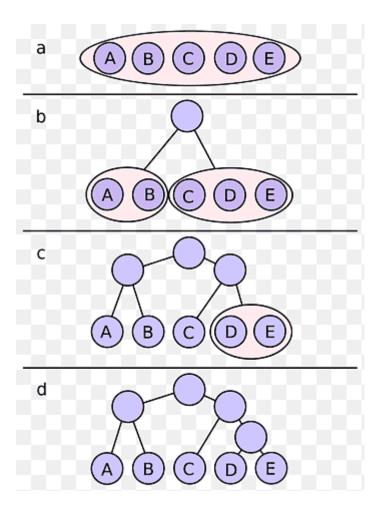
3CM13

01-Junio-2021

### Algoritmo de Huffman.

Es un algoritmo utilizado para el cifrado de datos por medio de la frecuencia de aparición de caracteres y su clasificación en un árbol binario.

A través de la frecuencia de aparición de caracteres en determinada cadena, el algoritmo de Huffman calcula los pesos del conjunto de símbolos y los coloca en un árbol binario. El ordenamiento de los caracteres se balancea de forma que los caracteres más solicitados, son los que contienen menor cantidad de caracteres binarios.



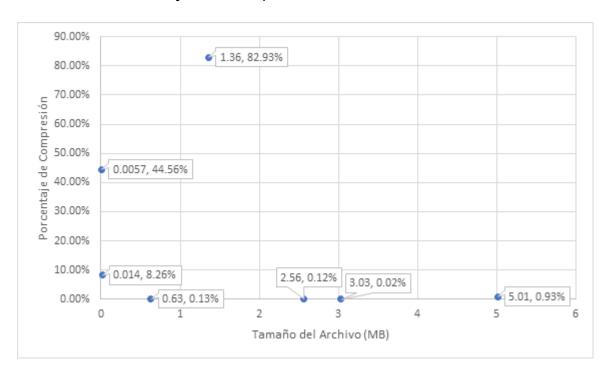
La complejidad del algoritmo de Huffman es: O(nlog(n))

### Desarrollo de la Práctica.

#### Archivos usados.

Extensión de Archivo	Peso en MB
TXT	0.0057
MP3	5.01
ВМР	1.36
JPG	0.63
PDF	2.56
DOCX	0.014
PNG	3.03

### Gráfica de Porcentaje de Compresión.



Como podemos ver el tamaño del archivo no es influyente en que tanto se va a comprimir nuestro archivo, esto depende de que tan óptimo sea ese archivo un archivo más óptimo tendrá una compresión menor a uno que no lo es.

Tiempos de ejecución para la codificación y decodificación de diferentes archivos procesados por el programa.

Archivo	Codificación(segundos)	Decodificación(segundos)
TXT	0.008s	0.002s
MP3	5.571s	0.857s
ВМР	0.515s	0.025s
JPG	0.682s	0.110s
PDF	2.793s	0.385s
W	0.051s	0.022s
PNG	3.220s	0.452s

#### Complejidad de las funciones implementadas en el programa.

- $\star$  Complejidad de la función main():  $O(n \log n)$
- $\star$  Complejidad de la función imprime Tabla Frecuencias: O(n)
- $\star$  Complejidad de la función genera frecuencias():  $O(n^{-2})$
- $\star$  Complejidad de la función: insertaFrecuencia: O(n)
- $\star$  Complejidad de la función vectorFrecuencia():  $O(n^{-2})$
- $\star$  Complejidad de la función ordenaFrecuenciasPorAparicion:  $O(n^{-2})$
- $\star$  Complejidad de la función crearArbolCodificacion(): O(n)
- $\bigstar$  Complejidad de la función generaUnicoArbol():  $O(n^{-2})$
- ★ Complejidad de la función reordenaArboles(): O(2 log(n))=O(log n)
- $\star$  Complejidad de la función obtieneCaminoR(): O(1)
- $\star$  Complejidad de la función ordenaVectorFrecuenciasPorCaracter():  $O(n^{-2})$
- $\star$  Complejidad de la función escribeBits(): O(n)
- $\star$  Complejidad de la función asignaCodificacion(): O(n)
- $\star$  Complejidad de la función buscaFrecuencias(): O(n)
- $\star$  Complejidad de la función decodificaBits:  $O(n^{-2})$
- $\star$  Complejidad de la función iniciaCola(): O(1)
- $\star$  Complejidad de la función formaCodificacion(): O(1)
- $\star$  Complejidad de la función formalnicioCodificacion(): O(1)
- $\star$  Complejidad de la función atiendeCola(): O(n)
- $\bigstar$  Complejidad de la función atiendeTodos(): O(n)
- $\bigstar$  Complejidad de la función pon1(): O(1)
- $\bigstar$  Complejidad de la función pon0(): O(1)
- $\bigstar$  Complejidad de la función valorBits(): O(1)

### Preguntas.

- i. ¿Los niveles de codificación de archivos proporcionan una ventaja respecto al tamaño del archivo original en el promedio de los casos?
- Si, en la mayoría de los casos, sí
- ii.¿Los tiempos de codificación o decodificación del archivo son muy grandes? Realmente no, pero todo depende del tamaño del archivo que estemos ingresando
- iii. ¿Ocurrieron pérdidas de la información al codificar los archivos?Aparentemente no se encontró ninguna pérdida de información en los archivos
- iv. ¿El comportamiento experimental del algoritmos era el esperado? Completamente el algoritmo cumplió con lo esperado. ¿Por qué?

Pues logró comprimir en distintos rangos, la información que era ingresada al programa

# v. ¿Qué características debería tener una imagen BMP para codificarse en menor espacio?

La calidad o definición de los pixeles de la imagen sea de una calidad media o promedio.

# vi. ¿Qué características debería tener un archivo de texto para tener una codificación en menor espacio?

El tipo de archivo que es, si tiene imagenes o si es un texto plano, etc

## vii.De 3 aplicaciones posibles en problemas de la vida real a la codificación de Huffman.

La codificación de Huffman hoy en día se usa a menudo como un "back-end" para algún otro método de compresión. DEFLATE (algoritmo de PKZIP) y códecs multimedia como JPEG y MP3 tienen un modelo front-end y cuantificación seguido de codificación Huffman.

# viii. ¿Existió un entorno controlado para realizar las pruebas experimentales? ¿Cuál fue?

Si, se realizó en una máquina virtual de una computadora con 16 Ram, Ryzen 2600 y GPU Radeon 5500xt.

# ix. ¿Qué recomendaciones darían a nuevos equipos para realizar esta práctica? Que sean pacientes, es un código bastante largo y que necesita bastante atención al momento de codificarse, pero no es imposible

#### Anexos.

#### Compilación:

Para la compilación del código se implementó en el archivo "huffman.sh" una serie de scripts para que de esta manera sea mas rapida la ejecución del programa para cada archivo de entrada que se quiera codificar así como una misma serie de script para llevar a cabo la descompresión. El comando a ejecutar es mediante la terminal de linux, accediendo a la ruta donde se encuentre el archivo "huffman.sh" posteriomente, se ejecutara con el comando "./huffman.sh", despues de la ejecucion observaremos como se ha generado un archivo de texto "registro.txt" en donde se guardo toda la información de los tiempos de compresión y descompresión así como el peso de cada archivo

#### Script de ejecución:

```
gcc 'practica3.c' -o 'practica3' -w
./practica3 0 texto.txt texto comp.txt caracteres1.txt >registro.txt
./practica3 0 cancion.mp3 cancion comp.txt caracteres2.txt
>>registro.txt
./practica3 0 imagen1.bmp imagen1 comp.txt caracteres3.txt
>>registro.txt
./practica3 0 imagen2.jpg imagen2 comp.txt caracteres4.txt
>>registro.txt
./practica3 0 pdf.pdf pdf comp.txt caracteres5.txt >>registro.txt
./practica3 0 word.docx word comp.txt caracteres6.txt >>registro.txt
./practica3 0 imagen3.png imagen3 comp.txt caracteres7.txt
>>registro.txt
./practica3 1 caracteres1.txt texto comp.txt texto desc.txt
>>registro.txt
./practica3 1 caracteres2.txt cancion comp.txt cancion desc.mp3
>>registro.txt
./practica3 1 caracteres3.txt imagen1 comp.txt imagen1 desc.bmp
>>registro.txt
./practica3 1 caracteres4.txt imagen2 comp.txt imagen2 desc.jpg
>>registro.txt
./practica3 1 caracteres5.txt pdf comp.txt pdf desc.pdf >>registro.txt
./practica3 1 caracteres6.txt word comp.txt word desc.docx
>>registro.txt
```

```
./practica3 1 caracteres7.txt imagen3_comp.txt imagen3_desc.png
>>registro.txt
```

Comando de ejecución del script en linux bash:



### Código

```
#include <stdio.h>
#include <stdlib.h>
#include "practica3.h"
int main(int argc, char** argv) {
   char * salida;
   char * codificado;
   int leidos;
   float leidosTotal = 0;
   float bytesTotal = 0;
   int bitsEscritosReal = 0;
    Frecuencia * v;
    char opc1 = argv[1][0];
    if(opc1 == '1') // Decompresión
        uswtime(&usrtime11, &systime11, &walltime11);
        tablaFrecuenciasArchivo = fopen(argv[2], "r");
        entrada = fopen(argv[3],"rb");
        out = fopen(argv[4], "wb");
        if(out == NULL || tablaFrecuenciasArchivo == NULL || entrada ==
NULL) printf("Error\n");
```

```
long size;
        char caracter;
        int apariciones;
        int padding;
        int tamanoOriginal;
        int numeroCaracteres;
        char basura;
        fseek (entrada, 0, SEEK END);
        size = ftell(entrada);
        rewind(entrada);
        fscanf(tablaFrecuenciasArchivo,"L:%d",&numeroCaracteres); // El
        fscanf(tablaFrecuenciasArchivo, "%c", &basura); // Salto de línea
        fscanf(tablaFrecuenciasArchivo,"P:%d",&padding); // El número
de bits "basura"
        fscanf(tablaFrecuenciasArchivo, "%c", &basura); // Salto de línea
        fscanf(tablaFrecuenciasArchivo,"B:%d",&tamanoOriginal); // El
        salida = (char *)malloc(sizeof(char)*tamanoOriginal);
        codificado = (char *)malloc(sizeof(char)*size);
        v = (Frecuencia *)malloc(sizeof(Frecuencia) *
numeroCaracteres);
        for(leidos = 0; leidos < numeroCaracteres; leidos++){</pre>
            fscanf(tablaFrecuenciasArchivo, "%c", &basura); // Salto de
fscanf(tablaFrecuenciasArchivo,"%c|%d",&caracter,&apariciones);
            Frecuencia f;
```

```
f.caracter = caracter;
            f.apariciones = apariciones;
            v[leidos] = f;
        fclose(tablaFrecuenciasArchivo);
        ordenaFrecuenciasPorAparicion(v, numeroCaracteres);
        creaArbolCodificacion(v,numeroCaracteres);
        fread(codificado, sizeof(char), size, entrada);
        fclose(entrada); // Cerramos el flujo de salida
        decodificaBits(codificado, (size*8) - padding, salida);
        fwrite(salida, sizeof(char), tamanoOriginal, out); // Escribimos
        fclose(out); // Cerramos el flujo
        uswtime(&usrtime21, &systime21, &walltime21);
        ImprimirTiempos(usrtime11, systime11, walltime11, usrtime21,
systime21, walltime21);;
        printf("Se ha descomprimido el archivo %s con exito, ahora es
%s\n",argv[3], argv[4]);
   else if(opc1 == '0') {
        uswtime(&usrtime11, &systime11, &walltime11);
        f.inicio = NULL;
        entrada = fopen(argv[2], "rb");
        if (entrada == NULL) {
            perror("No se puede abrir el fichero de entrada");
```

```
return -1;
        uswtime(&usrtime11, &systime11, &walltime11);
            leidos = fread(buffer, sizeof(char), BUFFER, entrada);
            leidosTotal += leidos;
            generaFrecuencias(&f,buffer,leidos);
        salida = (char *)malloc(sizeof(char) * leidosTotal);
        v = vectorFrecuencias(&f);
        creaArbolCodificacion(v,f.length);
        rewind(entrada);
        int resultadoEscritura = 0;
            leidos = fread(buffer, sizeof(char), BUFFER, entrada);
dentro de este ciclo
            for(iaux = 0; iaux < leidos; iaux++){</pre>
                resultadoEscritura =
escribeBits(salida,leidosTotal*8,bitsEscritosReal, buffer[iaux], v,
f.length);
                if(resultadoEscritura < 0) break;</pre>
```

```
bitsEscritosReal += resultadoEscritura;
de salida, rompemos el ciclo
       }while(leidos == BUFFER && resultadoEscritura >= 0);
       fclose(entrada); // Cerramos la entrada
       bytesTotal = (bitsEscritosReal / 8); // Determinamos cuantos
        int padding = ((int)(bytesTotal)) % 8;
        if(padding > 0)
            bytesTotal++;
       out = fopen(argv[3], "w"); // Abrimos un flujo de salida para
        fwrite(salida, sizeof(char), bytesTotal, out); // Escribimos el
arreglo de chars, el cual fue modificado para contener la información
       fclose(out); // Cerramos el flujo
        imprimeTablaFrecuencias(v,f.length, padding, leidosTotal
,argv[4]);
       uswtime(&usrtime21, &systime21, &walltime21);
        ImprimirTiempos(usrtime11, systime11, walltime11, usrtime21,
systime21, walltime21);
        float resta = (leidosTotal - bytesTotal) *100;
        float porciento = resta/leidosTotal;
        if(resultadoEscritura >= 0)
            printf("Se ha comprimido %s con exito, paso de %.0f bytes a
8.0f bytes (%.2f%), ahora se encuentra en
s",argv[2],leidosTotal,bytesTotal,porciento, argv[3]);
```

```
else
            printf("NO se ha comprimido %s con exito, paso de %.0f
bytes a %.0f bytes, ahora se encuentra en
s",argv[2],leidosTotal,bytesTotal, argv[3]);
   return (EXIT SUCCESS);
 * @param frecuencias La tabla de frecuencias en el archivo
 * @param ruta La ruta en la que se debe guardar
void imprimeTablaFrecuencias(Frecuencia * frecuencias, int length, int
padding, int byteOrginal,const char ruta[]) {
   tablaFrecuenciasArchivo = fopen(ruta, "w");
   if (tablaFrecuenciasArchivo == NULL) {
       perror("No se puede abrir archivo");
    fprintf(tablaFrecuenciasArchivo,"L:%d\n", length);
   fprintf(tablaFrecuenciasArchivo, "P:%d\n", padding);
    fprintf(tablaFrecuenciasArchivo, "B:%d\n", byteOrginal);
   for (i = 0; i < length; i++) {
        fprintf(tablaFrecuenciasArchivo,"%c|%d\n"
                , (int) frecuencias[i].caracter
                , frecuencias[i].apariciones
                /*, frecuencias[i].codigo*/);
   fclose(tablaFrecuenciasArchivo);
 * @param frecuencias Un apuntador a la lista
 * @param caracteres Los caracteres a insertar
 * @param length La longitud del arreglo de caracteres a insertar
```

```
oid generaFrecuencias(ListaFrecuencia * frecuencias, char
caracteres[], int length) {
   if (frecuencias->inicio == NULL) {
       frecuencias->length = 0;
   int ix;
de frecuencia
   for (ix = 0; ix < length; ix++) {
       insertaFrecuencia(frecuencias, caracteres[ix]);
 * @param frecuencias La lista de frecuencias
 * @param caracter El caracter que queremos insertar o actualizar
void insertaFrecuencia(ListaFrecuencia * frecuencias, char caracter) {
   NodoFrecuencia * f;
   for(f = frecuencias->inicio, fanterior = frecuencias->inicio;f !=
NULL; f = f->siguiente)
       if (f->frecuencia.caracter == caracter) {
            f->frecuencia.apariciones++;
            int ix = 0;
acomodamos
que quede en orden
            if( f->siguiente != NULL
```

```
&& f->frecuencia.apariciones >
f->siguiente->frecuencia.apariciones)
                NodoFrecuencia * auxiliar = f->siguiente;
                if(f == frecuencias->inicio)
                    frecuencias->inicio = f->siguiente;
                    f->siguiente = auxiliar->siguiente;
                    frecuencias->inicio->siguiente = f;
                    fanterior->siguiente = f->siguiente;
                    f->siguiente = fanterior->siguiente->siguiente;
                    fanterior->siquiente->siquiente = f;
        fanterior = f;
    f = (NodoFrecuencia *) malloc(sizeof (NodoFrecuencia));
    f->frecuencia.caracter = caracter;
    f->frecuencia.apariciones = 1;
    f->siguiente = aux;
    frecuencias->inicio = f;
    frecuencias->length++;
```

```
* @param frecuencias La lista de frecuencias a convertir
Frecuencia * vectorFrecuencias(ListaFrecuencia * frecuencias){
    Frecuencia * vector = (Frecuencia *) malloc(sizeof(Frecuencia) *
frecuencias->length);
   NodoFrecuencia * f;
    for(f = frecuencias->inicio;f != NULL; f = f->siguiente, i++) {
        vector[i] = f->frecuencia;
    ordenaFrecuenciasPorAparicion(vector, frecuencias->length);
    return vector;
void ordenaFrecuenciasPorAparicion(Frecuencia * vector, int length){
    Frecuencia temp;
    for(i=0;i<length-1;i++)</pre>
        for(j=0;j<length-1;j++)</pre>
            if (vector[j].apariciones > vector[j+1].apariciones)
                temp=vector[j];
                vector[j]=vector[j+1];
                vector[j+1]=temp;
 * @param frecuencias Un arreglo con las frecuencias ordenadas
```

```
@param length La longitud del arreglo de frecuencias
void creaArbolCodificacion(Frecuencia * frecuencias, int length) {
   nodos = length;
   bosqueHuffman = (NodoArbol **) malloc(sizeof(NodoArbol *) * length);
   for(i = 0; i < length; i++) {
       NodoArbol * hoja = (NodoArbol *)malloc(sizeof(NodoArbol));
       hoja->frecuencia = &(frecuencias[i]); // Guardamos la
       hoja->peso = frecuencias[i].apariciones; // Para el paso uno el
       hoja->nodo0 = NULL; // Son hojas
       hoja->nodo1 = NULL; // Son hojas
       hoja->visitado = 0; // Lo marcamos como no visitado
       bosqueHuffman[i] = hoja;
   generaUnicoArbol();
   for(i = 0; i < length; i++) {
       ColaCodificacion * cola = (ColaCodificacion
*) malloc(sizeof(ColaCodificacion));
       iniciaCola(cola);
       obtieneCaminoR(bosqueHuffman[0], cola);
       asignaCodificacion(frecuencias, length, cola);
       free(cola);
void generaUnicoArbol() {
```

```
int i = nodos, j;
   while(bosqueHuffman[1] != NULL) { // Mientras no tengamos un solo
       NodoArbol * nuevaHoja = (NodoArbol *)malloc(sizeof(NodoArbol));
       nuevaHoja->frecuencia = NULL;
       nuevaHoja->peso = bosqueHuffman[0]->peso +
bosqueHuffman[1]->peso; // La suma de los pesos de sus dos hijos
       nuevaHoja->nodo0 = bosqueHuffman[0]; // Hijo de menor
        nuevaHoja->nodo1 = bosqueHuffman[1]; // Hijo de mayor
       nuevaHoja->visitado = 0; // Lo marcamos como no visitado
        for (j = 2; j < i; j++) {
            bosqueHuffman[j - 1] = bosqueHuffman[j];
       bosqueHuffman[j-1] = NULL;
       bosqueHuffman[0] = nuevaHoja;
       reordenaArboles();
void reordenaArboles(){
```

```
int i,j;
   for(i = 0; i < nodos && bosqueHuffman[i] != NULL; i++){</pre>
       for(j = 0; j < nodos && bosqueHuffman[j+1] != NULL; j++)</pre>
           if(bosqueHuffman[j]->peso > bosqueHuffman[j+1]->peso)
                temp=bosqueHuffman[j];
               bosqueHuffman[j]=bosqueHuffman[j+1];
               bosqueHuffman[j+1]=temp;
* @param arbol El árbol donde está la codificación
void obtieneCaminoR(NodoArbol * arbol, ColaCodificacion * cola) {
       if(arbol->nodo0 && arbol->nodo0->visitado == 0)
           formaCodificacion(cola,'0');
       else if(arbol->nodo1 && arbol->nodo1->visitado == 0)
           formaCodificacion(cola,'1');
           obtieneCaminoR(arbol->nodo1, cola);
```

```
arbol->visitado = 1;
            if(arbol->frecuencia != NULL)
formaInicioCodificacion(cola,arbol->frecuencia->caracter);
            formaCodificacion(cola,'\0');
            if(arbol->nodo0->visitado == 1 && arbol->nodo1->visitado ==
                arbol->visitado = 1;
* @param frecuencias
* @param length
void ordenaVectorFrecuenciasPorCaracter(Frecuencia * frecuencias, int
length) {
   for(;ix < length; ++ix) // Recorremos el arreglo</pre>
        Frecuencia temp = frecuencias[ix];
```

```
int j = ix - 1;
       while((frecuencias[j].caracter > temp.caracter) && (j >= 0))
            frecuencias[j + 1] = frecuencias[j];
       frecuencias[j + 1] = temp;
* @param salida Es un arreglo de caracteres al cual se le van a
modificar los bits
 * @param salidaLength El tamaño en bits del arreglo
* @param pointer La posición a partir de la cual se comenzar a
* @param frecuencias El arreglo de las frecuencias
 * @param length El tamaño del arreglo de frecuencias
int escribeBits(char * salida, int salidaLength, long pointer, char c,
Frecuencia * frecuencias, int length) {
   int bitsescritos;
   int indiceFrecuencia = buscaFrecuencia(frecuencias, 0, length, c);
   Frecuencia f = frecuencias[indiceFrecuencia];
   for(bitsescritos = 0; f.codigo[bitsescritos] != '\0';
bitsescritos++)
       if(f.codigo[bitsescritos] == '1')
            pon1(salida,pointer + bitsescritos);
        else if(f.codigo[bitsescritos] == '0')
            pon0(salida,pointer + bitsescritos);
```

```
return bitsescritos;
* @param frecuencias Un arreglo de frecuencias ordenado
 * @param length El tamaño del arreglo de frecuencias
void asignaCodificacion(Frecuencia * frecuencias, int length,
    char caracter = atiendeCola(cola);
    int longitudCodigo = cola->count;
    int indiceFrecuencia = buscaFrecuencia(frecuencias, 0, length,
caracter);
    int i;
    frecuencias[indiceFrecuencia].codigo = (char
*)calloc(longitudCodigo-1,sizeof(char));
    for(i = 0; i < longitudCodigo; i++) {</pre>
        frecuencias[indiceFrecuencia].codigo[i] = atiendeCola(cola);
 * @param frecuencias
* @param final
   int i = -1;
    for(inicio = 0; inicio < final; inicio++)</pre>
       if(frecuencias[inicio].caracter == c){
            i = inicio;
```

```
return i;
 * @param codificado El arreglo de caracteres leído del archivo
 * @param longitudCodificado El tamaño del arreglo codificado
void decodificaBits(char * codificado, long longitudCodificado, char *
salida){
   int v;
   int charSalida = 0;
   NodoArbol * aux = bosqueHuffman[0];
    for(x= 0; x < longitudCodificado;){</pre>
        while(aux->frecuencia == NULL) {
            v = valorBit(codificado, x++);
            if (v == 0) \{ aux = aux -> nodo0; \}
            else if (v == 1) \{ aux = aux -> nodo1; \}
        salida[charSalida++] = aux->frecuencia->caracter;
       aux = bosqueHuffman[0];
void iniciaCola(ColaCodificacion * cola) {
    cola->count = 0;
```

```
cola->final = NULL;
void formaCodificacion(ColaCodificacion * cola, char valor){
   NodoCola * nuevoNodo = (NodoCola *)malloc(sizeof(NodoCola));
   nuevoNodo->valor = valor;
   nuevoNodo->siguiente = NULL;
   if(cola->final == NULL) {
       cola->final = nuevoNodo;
       cola->inicio = nuevoNodo;
       cola->final->siguiente = nuevoNodo;
       cola->final = nuevoNodo;
   cola->count++;
void formaInicioCodificacion(ColaCodificacion * cola, char valor){
   NodoCola * nuevoNodo = (NodoCola *)malloc(sizeof(NodoCola));
   nuevoNodo->valor = valor;
   nuevoNodo->siguiente = cola->inicio;
   cola->inicio = nuevoNodo;
   cola->count++;
char atiendeCola(ColaCodificacion * cola){
   char val = cola->inicio->valor;
   cola->inicio = cola->inicio->siguiente;
   cola->count--;
   free(aux);
   return val;
void atiendeTodos(ColaCodificacion * cola){
   while(cola->inicio != NULL) {
       atiendeCola(cola);
   cola->count == 0;
```

```
* @param pos La posición del bit que queremos cambiar
void pon1(char * array, int pos){
   int ix = pos / BYTE;
   int i = pos - (BYTE * ix);
   PONE 1(array[ix],i);
* @param array El arreglo en el que queremos modificar
* @param pos La posición del bit que queremos cambiar
void pon0(char * array, int pos){
   int ix = pos / BYTE;
   int i = pos - (BYTE * ix);
   PONE 0 (array[ix],i);
* @param pos La posición del bit que queremos obtener
int valorBit(char * array, int pos){
   int ix = pos / BYTE;
   int i = pos - (BYTE * ix);
   return COGEBIT(array[ix],i);
```

### Referencias consultadas:

→ B. (2017, 4 septiembre). *Algoritmo de Huffman - BackStreetCode*. Medium. https://medium.com/@aprendizaje.maq/algoritmo-de-huffman-8523c21a1b1a